

ERHA7016 – Hidrologia Estocástica

Introdução (pt. 2)

Daniel Detzel
detzel@ufpr.br

Agenda

Revisão de estatística
testes de hipótese

Processos estocásticos
definições
propriedades

Análise de séries temporais
definição e propriedades
características de séries hidrológicas
persistência



REVISÃO DE ESTATÍSTICA

testes de hipótese

Revisão de estatística | testes de hipótese

Testes de hipótese:

Regra de decisão para rejeitar, ou não, uma hipótese com base na amostra

Hipótese: suposição que algo pode ser verdade, ou não. Deve ser passível de testes

Hipóteses estatísticas

H_0 – hipótese nula: o que se assume ser verdade

H_1 – hipótese alternativa: o que se assume ser verdade quando da rejeição de H_0

ex. de H_0 : a distribuição dos dados é Normal; as amostras não têm a mesma média; a série não tem tendência; etc.

Revisão de estatística | testes de hipótese

Cada teste possui um procedimento matemático específico


Em comum, todos calculam a probabilidade (**p-valor**) de os dados terem sido observados assumindo que H_0 é verdadeira

$$P(\text{Dados} \mid H_0 \text{ verdadeira}) = \text{p-valor}$$

Por sua vez, o analista assume um **risco** de se tomar a decisão errada
em particular, rejeitar H_0 quando ela é verdadeira
o risco é quantificado pelo **nível de significância α**
valores típicos de α : 1%, 5% e 10%

Revisão de estatística | testes de hipótese

Em suma:



Se o p-valor:

Baixo ($\text{p-valor} \leq \alpha$) \rightarrow rejeita-se a hipótese nula

Alto ($\text{p-valor} > \alpha$) \rightarrow falha-se em rejeitar a hipótese nula

Revisão de estatística | testes de hipótese

Testes de hipótese são construídos com base em premissas
os dados são independentes e identicamente distribuídos
as amostras possuem a mesma variância (homoscedásticas)

Adicionalmente, testes do tipo **paramétrico** assumem que a distribuição de probabilidade dos dados **é conhecida**

o analista precisa adotar uma distribuição para os dados
perdem poder se a distribuição adotada não for adequada

Testes não paramétricos, não têm essa premissa

perdem poder se a distribuição de probabilidades dos dados é conhecida

Revisão de estatística | distribuições de probabilidades

Como escolher a distribuição a ser adotada?

1. Avaliação por métodos gráficos
2. Aplicação de testes de hipótese para adequação de ajustes

2. Testes de adequação de ajustes

- 2.1. Shapiro-Wilk (para normalidade)
- 2.2. Anderson-Darling
- 2.3. Filliben/PPCC (*probability plot correlation coefficient*)



Exemplos na sequência usam a série dos níveis mínimos anuais do rio Nilo

Revisão de estatística | distribuições de probabilidades

2.1. Shapiro-Wilk (para normalidade)


H_0 : a amostra vem de uma distribuição normal

H_1 : a amostra não vem de uma distribuição normal

Shapiro-Wilk normality test

$W = 0.99329$, $p\text{-value} = 0.004614$

Veredicto: rejeita-se H_0 (a distribuição não é normal)



2.2. Anderson-Darling

H_0 : a amostra vem de uma distribuição especificada

H_1 : a amostra não vem de uma distribuição especificada

Anderson-Darling test of goodness-of-fit


Null hypothesis: Normal distribution

Anmax = 1.5552, p-value = 0.9905

Null hypothesis: log-normal distribution

Anmax = 3.3899, p-value = 0.3714

Veredicto: falha-se em rejeitar H_0 (a distribuição é normal)



2.3. PPCC

H_0 : a amostra vem de uma distribuição especificada

H_1 : a amostra não vem de uma distribuição especificada


Probability Plot Correlation Coefficient Test

Null hypothesis: Normal distribution

ppcc = 0.99677, n = 663, p-value = 0.0073

Null hypothesis: log-normal distribution

ppcc = 0.82211, n = 663, p-value = 0.0039



Veredicto: rejeita-se H_0 (a distribuição não é normal, tampouco log-normal)

PROCESSOS ESTOCÁSTICOS

definições

Processos estocásticos | definições

Processos estocásticos:

Descrevem sistemas cuja **evolução** ocorre de acordo com **leis probabilísticas**

Um PE Z é uma **família de funções** definidas por:

$$Z = \{Z(t, \omega), t \in T; \omega \in \Omega\}$$

onde

t variável pertencente ao espaço de instantes T

ω evento do espaço de probabilidades Ω

Processos estocásticos | definições

Um PE pode ser visto como uma função de 2 variáveis, na qual para cada evento ω é atribuída uma variável t

Se $T \equiv \mathbb{Z} = \{1, \dots, t\} \rightarrow$ PE discreto $Z_{t,\omega}$ ou simplesmente Z_t

Se $T \in \mathbb{R} \rightarrow$ PE contínuo $Z(t, \omega)$ ou simplesmente $Z(t)$

Quando aplicado à modelagem de fenômenos naturais, frequentemente assume-se T como sendo finito ($T \equiv \mathbb{Z}$) e tendo o **tempo** como unidade

Os possíveis valores que a variável Z_t recebe são chamados de **estados**

Processos estocásticos | definições

Classificação dos modelos estocásticos

[Hipel e McLeod, 1994, p. 23]

		<i>Estados</i>	
		Discretos	Contínuos
<i>Tempo</i>	Discreto	Cadeias de Markov <i>[Wilks, 1998]</i>	Modelos de séries temporais
	Contínuo	Processos pontuais <i>[Abi-Zeit et al., 2004]</i>	Equações diferenciais estocásticas <i>[Breinholt et al., 2021]</i>

Processos estocásticos | definições

O PE $Z(t, \omega)$ representa 4 casos:

1. Com t e ω variáveis \rightarrow uma família de funções temporais
2. Com t variável e ω fixo \rightarrow uma função temporal única
3. Com t fixo e ω variável \rightarrow uma variável aleatória
4. Com t e ω fixos \rightarrow um número

Caso 2: definição de **série temporal** \rightarrow uma realização **infinita** do processo estocástico

Processos estocásticos | definições

Processos naturais \neq processos estocásticos

Séries observadas \neq realizações de um processo estocástico


	Processos (variáveis)	Séries temporais (valores)
Fenômeno natural	Processo natural	Séries observadas (únicas e finitas)
Modelo	Processo estocástico	Realizações (infinitas)

[Koutsoyiannis, 2006]

Processos estocásticos | definições

Processos naturais se tratam de **amostras** de uma realização de um PE


Representação de uma amostra de uma realização de um PE



Processos estocásticos | definições

Processos naturais se tratam de **amostras** de uma realização de um PE


Representação de 1 realização de um PE



Processos estocásticos | definições

Processos naturais se tratam de **amostras** de uma realização de um PE

Representação de 5 realizações de um PE



PROCESSOS ESTOCÁSTICOS

propriedades

Processos estocásticos | propriedades

Especificação de um PE:

A determinação de um PE Z envolve o conhecimento da FDA conjunta de todas as suas n (infinitas) realizações Z_n

$$F_{Z_1, \dots, Z_n}(z_1, \dots, z_n; t_1, \dots, t_n) = P\{Z(t_1) \leq z_1, \dots, Z(t_n) \leq z_n\}$$

caso unidimensional: a FDA $F_{Z_1}(z_1; t_1)$ é conhecida

caso bidimensional: as FDAs $F_{Z_1, Z_2}(z_1, z_2; t_1, t_2)$ são conhecidas

caso n -dimensional: as FDAs $F_{Z_1, \dots, Z_n}(z_1, \dots, z_n; t_1, \dots, t_n)$ são conhecidas

Processos estocásticos | propriedades

Os parâmetros são também representados por conjuntos

Média conjunta de Z (função média):

$$\mu_t = E[Z_t] = \int_{-\infty}^{\infty} z f_Z(z; t) dz$$

Covariância conjunta de Z (função de autocovariância – FACV):

$$\gamma(t_1, t_2) = COV[Z_{t_1}, Z_{t_2}] = E[Z_{t_1} Z_{t_2}] - E[Z_{t_1}] E[Z_{t_2}]$$

Processos estocásticos | propriedades

Estacionariedade:

Conceito relacionado com um estado de **equilíbrio estatístico** de um PE
propriedades estatísticas independem do tempo

Estacionariedade estrita (ou forte)

$$F_Z(z_1, \dots, z_n; t_1 + \tau, \dots, t_n + \tau) = F_Z(z_1, \dots, z_n; t_1, \dots, t_n)$$

para quaisquer $t_1, \dots, t_n, \tau \in T$

Processos estocásticos | propriedades

Aplicações práticas estão centradas em distribuições unidimensionais e momentos finitos

tipicamente momentos de primeira e segunda ordens

Estacionariedade ampla (ou fraca, ou de segunda ordem)

atendem às seguintes condições:

- i. $E[Z_t] = \mu_t = \mu = \text{cte.}$
- ii. $E[Z_t^2] < \infty$
- iii. $\gamma(t_1, t_2) = \text{COV}[Z_{t_1}, Z_{t_2}]$ é função apenas de $|t_1 - t_2|$

Processos estocásticos | propriedades

Ergodicidade:

Conceito muito utilizado na teoria de sistemas dinâmicos

estudo da trajetória de partículas em um sistema

sistema ergódico: as trajetórias têm a mesma probabilidade de passar pelos diversos estados que o compõem

as características do sistema inteiro podem ser inferidas com base na trajetória de 1 partícula

Paralelo com as realizações de um PE

um PE é ergódico quando suas estatísticas podem ser inferidas a partir de apenas uma série temporal

Processos estocásticos | propriedades

PE ergódico na média (primeira ordem)

$$\lim_{n \rightarrow \infty} \left(\frac{1}{n} \sum_{t=1}^n z_t \right) = E[Z_t] = \mu$$

PE ergódico na autocovariância (segunda ordem)

$$\lim_{n \rightarrow \infty} \left[\frac{1}{n} \sum_{t=1}^{n-k} (z_t - \mu_z)(z_{t+k} - \mu_z) \right] = COV[Z_t] = \gamma$$

Processos estocásticos | propriedades

PE ergódico na autocovariância (segunda ordem) – condição suficiente

$$\sum_{k=0}^{\infty} |\hat{\gamma}_k| < \infty$$

Fill [2011]: em se tratando de séries hidrológicas, quando o processo é estacionário é usual assumi-lo ergódico

ANÁLISE DE SÉRIES TEMPORAIS

definição e propriedades

Análise de séries temporais | definição e propriedades

Séries temporais:

Sequências de variáveis observadas e encadeadas temporalmente

Os intervalos de tempo entre registros **não precisam** ser uniformes

Para intervalos de tempo uniformes, é conveniente escolher uma escala Δt apropriada

a escolha tem relação com o propósito do estudo

ex. 1: cheias em bacias urbanas pequenas $\rightarrow \Delta t$ na escala de horas

ex. 2: balanço hídrico em grande bacias $\rightarrow \Delta t$ na escala de anos

Análise de séries temporais | definição e propriedades

Estacionariedade:


Importante: a estacionariedade é uma propriedade associada a processos estocásticos, não a séries temporais [ver discussão em *Koutsoyiannis, 2006*]
para séries: falamos em comportamento estacionário

Uma série tem comportamento estacionário quando suas estatísticas não variam com o tempo

tipicamente, a média e o desvio padrão são mantidos constantes
condição frequentemente violada em séries de fenômenos naturais

Análise de séries temporais | definição e propriedades

Comportamentos não estacionários de séries do cotidiano
sazonalidade, ciclos e tendências



Análise de séries temporais | definição e propriedades

Homogeneidade:

Para *Naghettini & Pinto [2007, p. 265]*

série homogênea: observações extraídas de uma **mesma população**

série não homogênea: observações advindas de **populações diferentes**

Séries não homogêneas:

no tempo: tendências, ou quebras de padrão (comportamento não estacionário)

na causa: terremotos, construção de uma barragem, bacias hidrográficas que recebem contribuição de degelo, etc.

Esta é uma definição comum em hidrologia e climatologia

Análise de séries temporais | definição e propriedades

Na literatura clássica de análise de séries temporais [Box et al., 2008], a homogeneidade está atrelada apenas a séries com **comportamento não estacionário**

Série estacionária

Série não
estacionária
homogênea

↓
Não estacionariedade
pode ser removida

Série não
estacionária e não
homogênea

↓
Não estacionariedade não
pode ser removida

(A técnica de **diferenciação**, usada na remoção da não estacionariedade em séries homogêneas, será apresentada na seção de transformações numéricas)

Análise de séries temporais | definição e propriedades

Homoscedasticidade:

Propriedade associada à **constância da variância** em relação ao tempo
uma série com variância variável é denominada **heteroscedástica**
dizer que uma série é heteroscedástica, é equivalente dizer que ela é não estacionária em relação à variância

Propriedade importante na avaliação dos **resíduos** de um modelo ajustado a uma determinada série
são bons indicadores da qualidade do modelo

(Técnicas de **estabilização da variância** são apresentada na seção de transformações numéricas)

ANÁLISE DE SÉRIES TEMPORAIS

características de séries hidrológicas

Análise de séries temporais | séries hidrológicas

Séries hidrológicas possuem particularidades relevantes
norteiam a escolha do modelo estocástico a ser utilizado

1. Têm valores quase sempre limitados a zero
dados negativos não possuem significado físico para diversas variáveis
exceções: evaporação líquida de reservatórios, cotas linimétricas (dependendo do referencial), temperatura do ar, etc.
2. Podem apresentar outliers
valores consideravelmente diferentes do restante da amostra
recomendável discernimento ao lidar com tais dados
ex.: é um erro de medição, ou um extremo hidrológico?

Análise de séries temporais | séries hidrológicas

3. Frequentemente não apresentam distribuição Normal
 - assimetrias positivas
 - requerem cuidados ao usar técnicas que requerem normalidade
 - problema minimizado por meio de transformações numéricas
4. São marcados por padrões sazonais
 - valores maiores ou menores dependendo do período do ano
 - podem ocorrer períodos sazonais distintos
 - ex.: estações do ano

5. Possuem persistência

dependência de um valor em relação às observações em seu entorno

no tempo: correlação serial

no espaço: correlação espacial (proximidade geográfica)

Em geral, uma série hidrológica apresenta todas essas características simultaneamente!


ANÁLISE DE SÉRIES TEMPORAIS

persistência


Análise de séries temporais | persistência

As séries mostradas têm estatísticas de média e desvio padrão **idênticas**

Série independente



Série persistente (níveis mínimos do rio Nilo)



Análise de séries temporais | persistência

Essencialmente: períodos de cheias tendem a ser seguidos por períodos de cheias (o mesmo para estiagens)

“Joseph Effect”

[Mandelbrot & Wallis, 1968]

Water Resources Research: 4, 1968, 909-918.

H10

Noah, Joseph, and operational hydrology (M & Wallis 1968)


... were all the fountains of the great deep broken up, and the windows of heaven were opened. And the rain was upon the earth forty days and forty nights. *Genesis: 6, 11-12.*

...there came seven years of great plenty throughout the land of Egypt. And there shall arise after them seven years of famine... *Genesis: 41, 29-30.*

Dedicated to Harold Edwin Hurst

Análise de séries temporais | persistência

Em geral, quanto menor a escala temporal, mais persistente é a série



A persistência é quantificada por meio de **correlações**

Análise de séries temporais | persistência

Coeficiente de correlação de Pearson: a mais bem conhecida medida de correlação

Mede a **associação linear** entre as variáveis

$$r = \frac{1}{n - 1} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right)$$

onde

\bar{x} e \bar{y}

médias de x e y , respectivamente

s_x e s_y

desvios padrão de x e y , respectivamente

n

tamanho da amostra

Análise de séries temporais | persistência

Para avaliar a persistência: correlação serial (ou correlação em série, ou autocorrelação)

medida de dependência linear entre os elementos de uma série:

$$\hat{r}_k = \frac{1}{n-1} \frac{\sum_{t=1}^{n-k} (x_t - \bar{x})(x_{t+k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2}$$

onde

k lag (defasagem temporal)

$$-1 \leq \hat{r}_k \leq 1$$

Análise de séries temporais | persistência

O gráfico \hat{r}_k vs. k é chamado de **correlograma** ou **função de autocorrelação amostral (FAC)**

em geral calculam-se os valores \hat{r}_k sequencialmente para $k = 1, 2, \dots, \max k$
o correlograma de uma série forma uma série
os valores de \hat{r}_k decaem progressivamente com o aumento de k

Sobre o *lag* máximo a ser considerado na FAC

atribuído pelo analista, de acordo com (i) o propósito da análise e com (ii) a escala temporal da série
alternativamente, pode-se adotar de 10% a 30% de n

Análise de séries temporais | persistência


Procura-se o *lag* para o qual $\hat{r}_k = 0 \rightarrow$ marca o fim da dependência
porém, devido a variações amostrais, os valores apenas flutuam em torno de 0
por isso definem-se intervalos de confiança IC_k :

$$IC_k = \pm z \sqrt{\frac{1}{n} \left(1 + 2 \sum_{t=1}^k \hat{r}_t^2 \right)}$$

onde $z = 1,96$ (para 95% conf.) ou $z = 2,58$ (para 99% conf.)

Análise de séries temporais | persistência

[Exemplo 1] Montagem do correlograma para as vazões médias mensais em Foz do Areia, no rio Iguaçu, para *lag* máximo de 36 meses.



Análise de séries temporais | persistência


Série histórica de abr./1968 a dez./2023

	\bar{Q} (m³/s) $k = 0$	\bar{Q} (m³/s) $k = 1$	\bar{Q} (m³/s) $k = 2$	
$\hat{r}_0 = 1$	253	253	253	
$\hat{r}_1 = 0,47$	167	167	167	
$\hat{r}_2 = 0,19$	159	159	159	
\vdots	186	186	186	
	
$\hat{r}_{36} = 0,03$	524	524	524	
	3315	3315	3315	
	2920	2920	2920	
	891	891	891	
		-	-	
		891	2920	
			58	
				...

Análise de séries temporais | persistência


Função de autocorrelação

não possui informação suficiente para determinar quando $\hat{r}_k = 0$






Análise de séries temporais | persistência

Função de autocorrelação após inclusão dos intervalos de confiança
correlação estatisticamente nula para $k = 5$





Análise de séries temporais | persistência

Correlogramas para vazões médias em diferentes escalas em Foz do Areia



Análise de séries temporais | persistência

Avaliação da sazonalidade mensal
por meio dos correlogramas



Testes de hipótese podem ser entendidos como regras de decisão para averiguações estatísticas

atenção para a diferença entre α e p-valor

Processos estocásticos são usados para a modelagem de sistemas que evoluem no tempo e que seguem premissas probabilísticas

séries temporais são amostras de uma das infinitas possíveis realizações de um processo estocástico

Séries hidrológicas apresentam características peculiares

propriedades relevantes: estacionariedade, homoscedasticidade, persistência



ERHA7016 – Hidrologia Estocástica

Daniel Detzel
detzel@ufpr.br