

ERHA7016 – Hidrologia Estocástica

# Geração de Séries Sintéticas

Análise de Séries Temporais (pt. 3)

Geração de Séries Sintéticas (pt. 1)

Daniel Detzel  
detzel@ufpr.br

Imagem: [bit.ly/2WhSPdF](https://bit.ly/2WhSPdF)

# Agenda

Análise de séries temporais  
decomposição

Geração de séries sintéticas  
modelos ARIMA  
modelos ARIMA: identificação



# **ANÁLISE DE SÉRIES TEMPORAIS**

## decomposição

# Análise de séries temporais | decomposição

Uma série temporal  $z_t$  pode ser compreendida como a composição de três termos:

$$z_t = S_t + T_t + a_t$$

onde

$S_t$       componente sazonal

$T_t$       componente de tendência/ciclo

$a_t$       componente residual



# Análise de séries temporais | decomposição

O equacionamento mostrado assume uma forma **aditiva** de representação  
há também a forma multiplicativa, mas é menos comum em séries hidrológicas

A forma do modelo pode variar de acordo com a escala considerada  
ex.: para série anuais, a componente  $S_t$  é inexistente

A componente residual  $a_t$  representa tudo aquilo que as demais componentes não conseguem extrair da série  
idealmente possui características aleatórias  
depende dos modelos utilizados para representar  $S_t$  e  $T_t$

# Análise de séries temporais | decomposição

Portanto, a decomposição de uma série diz respeito à aplicação de técnicas estatísticas para isolar  $S_t$  e  $T_t$  do sinal original  $z_t$

Aqui são consideradas três técnicas

- decomposição clássica

- decomposição STL

- decomposição CEEMDAN

As formulações detalhadas de cada método podem ser conferidas em:

- decomposições clássica e STL: <https://otexts.com/fpp3/decomposition.html>

- CEEMDAN: [Zhang et al., 2022]

# Análise de séries temporais | decomposição

## Decomposição clássica:

Procedimento simplificado que assume:

sazonalidade constante no decorrer dos anos

ciclo/tendência modelado a partir de médias móveis

1. Estimar a componente  $\hat{T}_t$

utilizar média móvel com janela equivalente a um ciclo sazonal completo

ex.: para séries mensais, adota-se janela temporal de 12 meses

# Análise de séries temporais | decomposição

## 2. Remover a componente de tendência do modelo

fazer:  $z_t - \hat{T}_t$

a série resultante possui as componentes  $S_t$  e  $a_t$

## 3. Estimar a componente $\hat{S}_t$

determinar a média de cada período sazonal da série ( $z_t - \hat{T}_t$ )

ex.: para séries mensais, calcular as médias de todos os janeiros, depois todos os fevereiros, etc.


## 4. Estimar a componente $\hat{a}_t$

fazer:  $\hat{a}_t = z_t - \hat{T}_t - \hat{S}_t$



# Análise de séries temporais | decomposição

*[Exemplo]* Decomposição clássica no rio São Francisco (usina Sobradinho)



# Análise de séries temporais | decomposição

## Decomposição STL:

STL: “*seasonal and trend decomposition using Loess*”

permite com que o comportamento sazonal varie com o passar dos anos  
ciclo/tendência pode ser não linear

considera que as componentes  $S_t$  e  $T_t$  estão interrelacionadas

Loess: “*locally weighted scatterplot smoothing*”

é um método de **regressão local**

em uma série, o método aplica sucessivas regressões em janelas móveis  
são ponderadas de modo que os pontos mais próximos do centro da janela  
tenham maior representatividade

# Análise de séries temporais | decomposição

A decomposição STL aplica um processo iterativo alternando ajustes Loess distintos para as componentes  $S_t$  e  $T_t$

1ª iteração:

idem à decomposição clássica para obter  $\hat{S}_t^1$  e  $\hat{T}_t^1$

2ª iteração:

obtem  $z_t - \hat{T}_t^1$  e aplica Loess para determinar  $\hat{S}_t^2$ ;

obtem  $z_t - \hat{S}_t^2$  e aplica Loess para determinar  $\hat{T}_t^2$

3ª iteração:


obtem  $z_t - \hat{T}_t^2$  e aplica Loess para determinar  $\hat{S}_t^3$ ;

obtem  $z_t - \hat{S}_t^3$  e aplica Loess para determinar  $\hat{T}_t^3$

*[repete até a convergência]*

# Análise de séries temporais | decomposição

*[Exemplo]* Decomposição STL no rio São Francisco (usina Sobradinho)



# Análise de séries temporais | decomposição

## Decomposição CEEMDAN:

CEEMDAN: “*complementary ensemble empirical mode decomposition with adaptive noise*”

variante aprimorada do método EMD (*empirical mode decomposition*)

Diferentemente das técnicas anteriores, o CEEMDAN assume que a série possui mais componentes do que  $S_t$  e  $T_t$

as componentes adicionais são consideradas **padrões oscilatórios**  
denominados IMFs (*intrinsic mode functions*)

# Análise de séries temporais | decomposição

Portanto, a decomposição pode ser representado por:

$$z_t = IMF_t^1 + IMF_t^2 + \dots + IMF_t^k + a_t$$

O processo de determinação das IMFs continua até que o que resta da série possa ser considerado como resíduo

o próprio algoritmo faz isso automaticamente

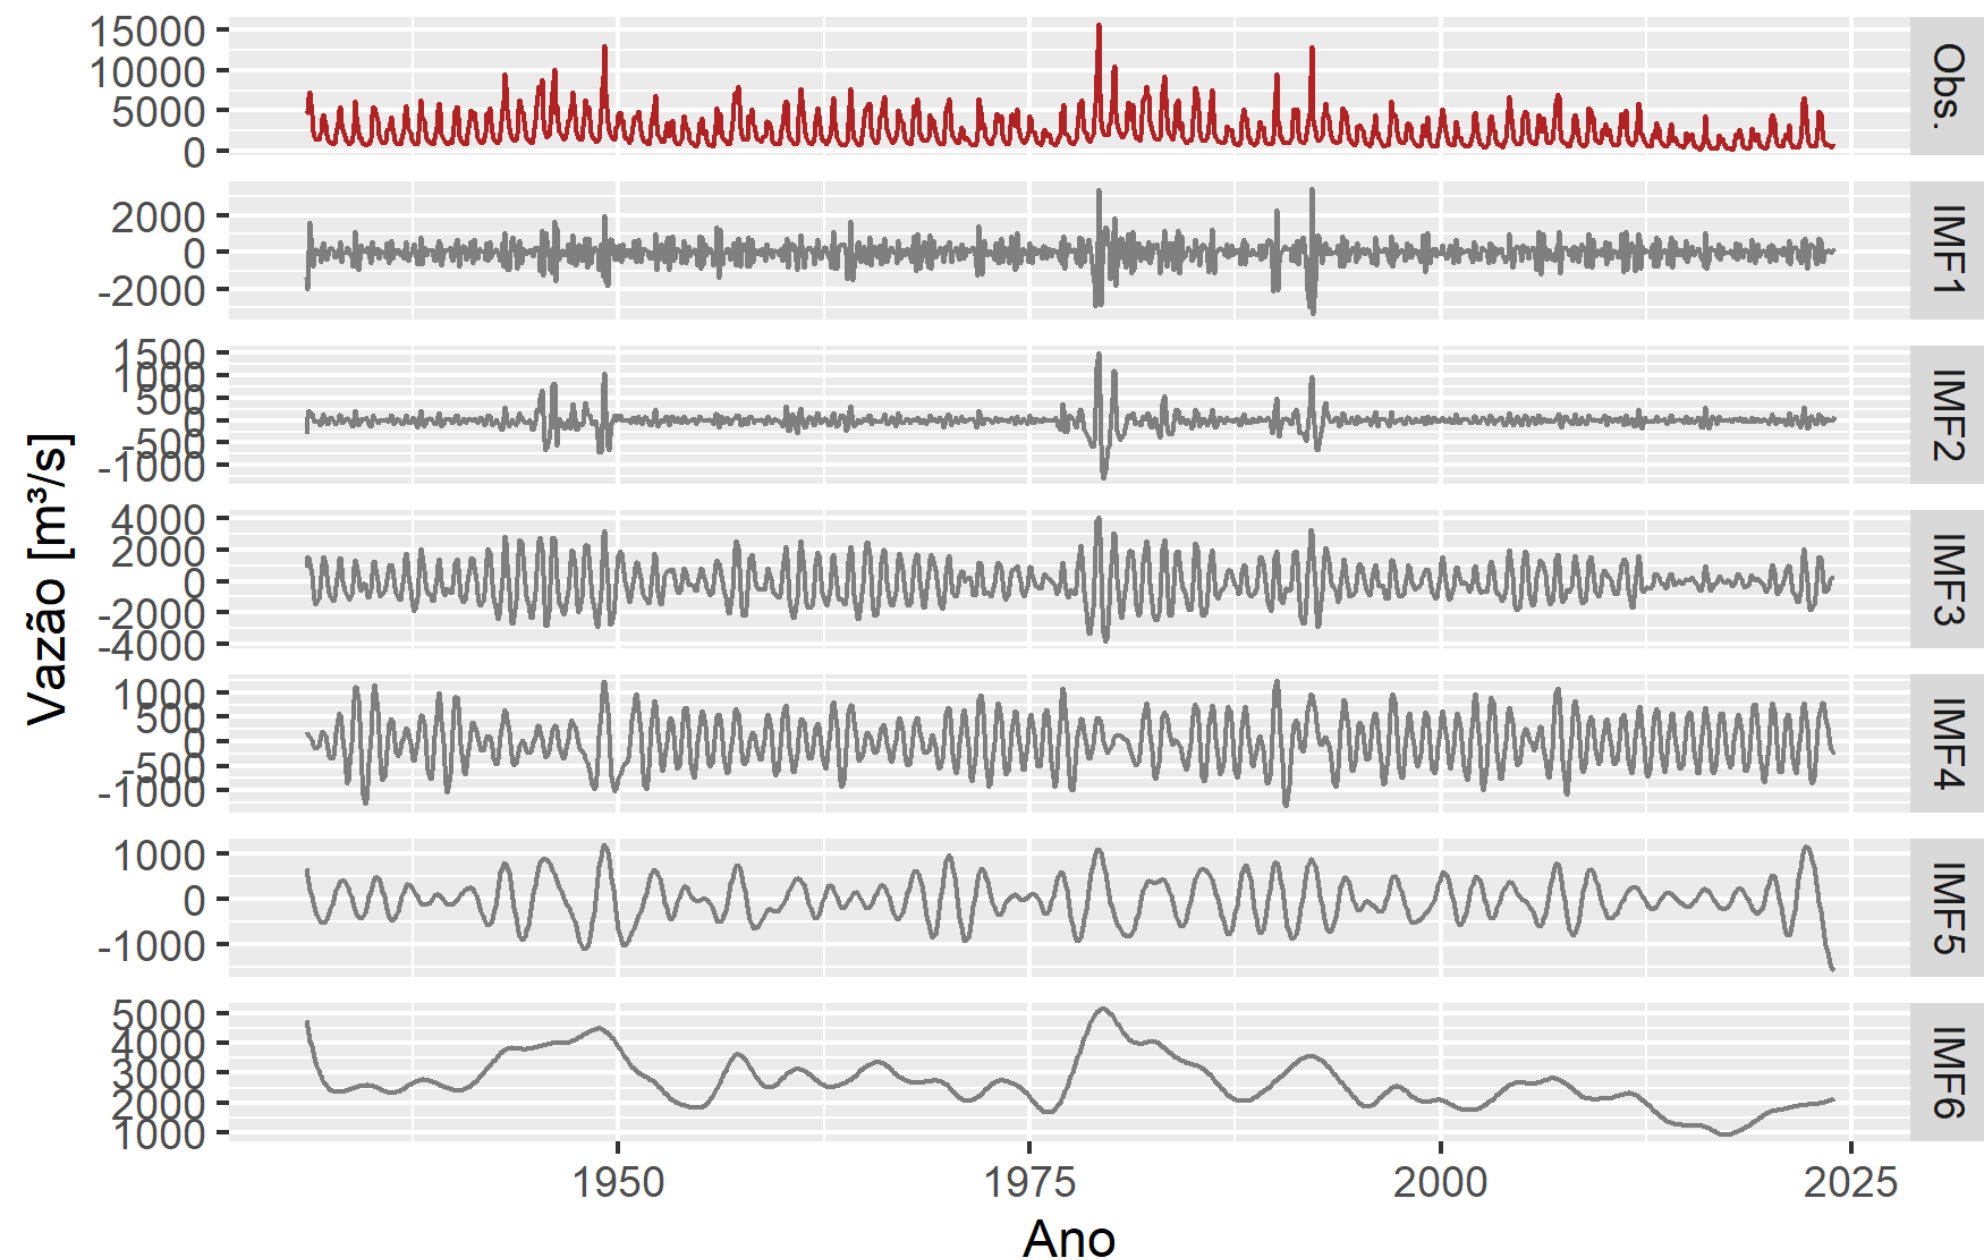
A partir de técnicas numéricas adicionais, é possível converter cada IMF em um frequência no domínio do tempo

ex.: oscilação com período de X anos

ver *[Antico et al., 2016]*



# Análise de séries temporais | decomposição




*[Exemplo]*  
Decomposição  
CEEMDAN no rio  
São Francisco  
(usina Sobradinho)

# GERAÇÃO DE SÉRIES SINTÉTICAS

## modelos ARIMA

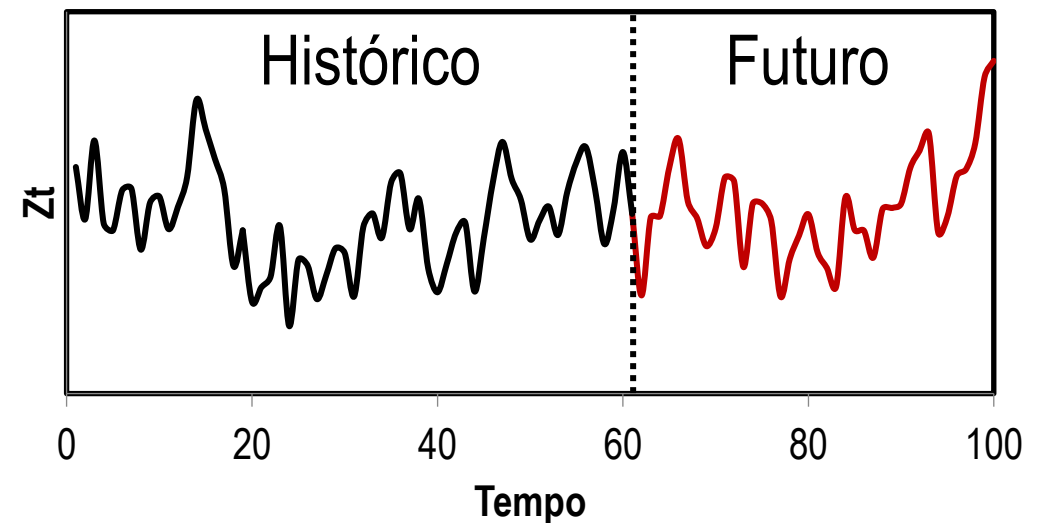
# Geração de séries sintéticas | modelos ARIMA

Geração de séries sintéticas  $\neq$  Previsão de séries



Geração de séries sintéticas

Previsão de uma série



# Geração de séries sintéticas | modelos ARIMA

## Principais modelos usados para geração de séries sintéticas

modelos estocásticos lineares (ARIMA) [Box et al., 2008]

*fractional gaussian noise* (FGN) [Mandelbrot & Wallis, 1969]

reamostragem via bootstrap [Srivastav & Simonovic, 2014] ou  $k$ -vizinhos mais próximos [Salas & Lee, 2010]

baseados em conceitos de entropia [Hao & Singh, 2011]

redes neurais artificiais [Can et al., 2012]

inferência *fuzzy* [Luna et al., 2011]

*wavelets* [Niu et al., 2013]

modelo de múltiplas escalas temporais (SSS) [Koutsoyiannis, 2002]

# Geração de séries sintéticas | modelos ARIMA

## Modelo de interesse: ARIMA

proposto por George Box e Gwilym Jenkins em 1970, com grande difusão a partir da 2ª edição de 1976\*

o mais popular para a geração de séries sintéticas de vazão  
exploram a estrutura de **persistência** da série

Sigla para modelo **A**uto**R**egressivo **I**ntegrado de **M**édias **M**óveis, baseia-se na combinação linear entre três elementos

componente autorregressivo: AR

fator de integração: I

componente de médias móveis: MA

---

\*Box, G. E. P.; Jenkins, G. M. (1976). **Time Series Analysis: Forecasting and Control** (Revised ed.). San Francisco, CA: Holden-Day

# Geração de séries sintéticas | modelos ARIMA

Para cada uso, o modelo deve ser construído por meio dos seguintes passos:

## 1. Identificação do modelo

Determinar quais componentes farão parte da formulação

## 2. Estimação dos parâmetros

Obter os valores dos parâmetros envolvidos

## 3. Validação do modelo

Avaliar, teoricamente, se o ajuste é satisfatório



# Geração de séries sintéticas | modelos ARIMA

Originalmente, o processo era iterativo

caso o modelo não fosse válido, retornava-se ao passo 1 para determinar um novo modelo

Atualmente é possível aplicar diferentes métodos construir um modelo ARIMA sem iterações

técnicas calcadas no [princípio da parcimônia](#)

“A técnica de Box e Jenkins requer experiência e algum conhecimento além do uso automático de um pacote de computador”

*[Morettin & Toloj, 2019]\**

---

\*Morettin, P.; Toloj, C. (2019). **Análise de series temporais**. 3ª Ed. São Paulo: Blücher.

# GERAÇÃO DE SÉRIES SINTÉTICAS

modelos ARIMA: identificação

# Geração de séries sintéticas | modelos ARIMA: identificação

Objetivo: determinar os componentes da formulação e as suas ordens

A representação geral do modelo é: ARIMA ( $p, d, q$ )

- o componente autorregressivo AR possui ordem  $p$

- o fator de integração I possui ordem  $d$

- o componente de médias móveis MA possui ordem  $q$

Uma série pode ser modelada pelos três elementos em conjunto, ou apenas parte deles

# Geração de séries sintéticas | modelos ARIMA: identificação

Equação geral do modelo

$$\underbrace{(1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p)}_{\text{AR}} \underbrace{(1 - B)^d}_I z_t = \underbrace{(1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q)}_{\text{MA}} a_t$$

onde

$B$  operador defasagem tal que  $z_{t-k} = B^k z_t$

$z_t$  variável aleatória no tempo  $t$

$a_t$  resíduo no tempo  $t$

# Geração de séries sintéticas | modelos ARIMA: identificação

Modelos de quaisquer ordens são obtidos a partir da equação geral

Exemplos:

$$\text{AR}(1): z_t - \varphi_1 z_{t-1} = a_t$$

$$\text{ARMA}(1,1): z_t - \varphi_1 z_{t-1} = a_t - \theta_1 a_{t-1}$$

$$\text{ARIMA}(1,1,1): (z_t - z_{t-1}) - \varphi_1 (z_{t-1} - z_{t-2}) = a_t - \theta_1 a_{t-1}$$

Essencialmente, a etapa de identificação busca:

- avaliar a pertinência de incluir as porções AR, I e/ou MA
- definir as ordens dos parâmetros  $p$ ,  $d$  e  $q$

# Geração de séries sintéticas | modelos ARIMA: identificação

Método convencional: análises das **funções de autocorrelação** (FAC) e **autocorrelação parcial** (FACP)

FAC (correlograma) foi definida na aula 2

FACP (correlograma parcial) é definida por:

$$\rho_j = \varphi_{k1} \cdot \rho_{j-1} + \varphi_{k2} \cdot \rho_{j-2} + \cdots + \varphi_{k(k-1)} \cdot \rho_{j-k+1} + \varphi_{kk} \cdot \rho_{j-k}$$


Equivale ao ajuste de sucessivos modelos autorregressivos de ordens  $p = 1, 2, \dots, k$  às séries

a FACP equivale aos últimos parâmetros  $\varphi_{kk}$  obtidos em cada ajuste



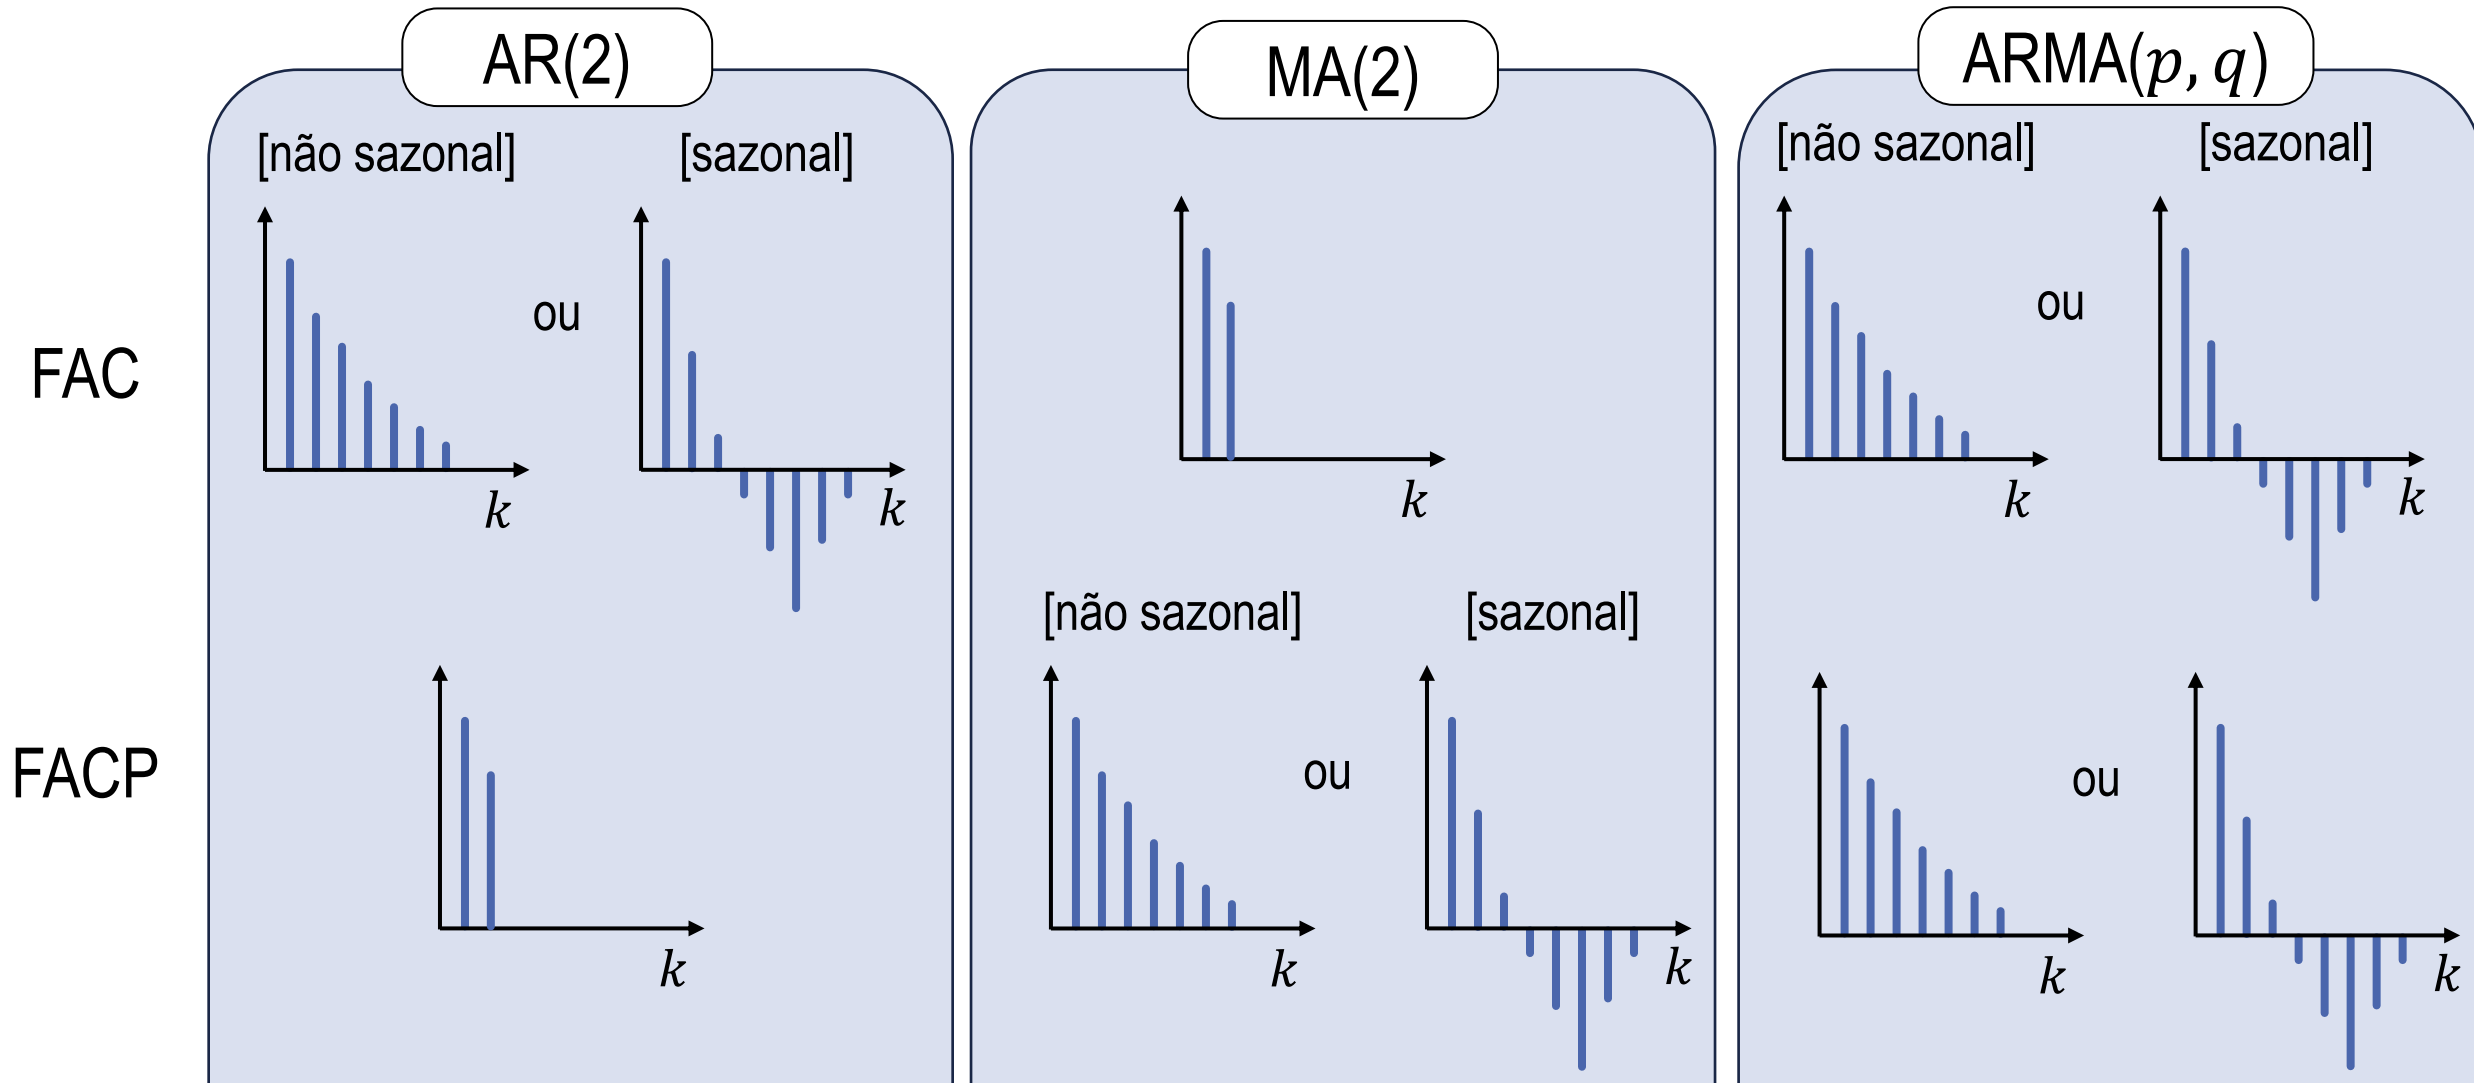
# Geração de séries sintéticas | modelos ARIMA: identificação

Comportamentos teóricos conhecidos para FAC e FACP [1ª ordem]:



# Geração de séries sintéticas | modelos ARIMA: identificação



Comportamentos teóricos conhecidos para FAC e FACP [2ª ordem]:



# Geração de séries sintéticas | modelos ARIMA: identificação

Por ser um critério visual, as análises via FAC e FACP podem ser subjetivas

Algumas séries são claras...  
Ex.: Salto Caxias (rio Iguaçu)





# Geração de séries sintéticas | modelos ARIMA: identificação

Por ser um critério visual, as análises via FAC e FACP podem ser subjetivas

Outras nem tanto...

Ex.: Itiquira II (rio Verde – MT)



# Geração de séries sintéticas | modelos ARIMA: identificação

Uma alternativa é calcular os chamados Critérios de Informação  
procedimentos matemáticos baseados em **funções penalizadoras** dependentes  
do número de parâmetros do modelo

Critérios de Akaike (AIC) e Akaike corrigido (AICc)  
objetivo: encontrar o modelo que mais bem representa a série

Critério Bayesiano (BIC)  
objetivo: encontrar o modelo mais parcimonioso

São calculados para todos os modelos candidatos. O modelo selecionado é o que  
resulta no **mínimo** AIC/AICc/BIC

# Geração de séries sintéticas | modelos ARIMA: identificação

Seja  $k$  o número total de parâmetros do modelo ( $p + q + 1$ )  
o parâmetro adicional se refere à variância dos resíduos do ajuste ( $\hat{\sigma}_a^2$ )

Os resíduos podem ser entendidos como erros do ajuste  
considerando **estimadores de máxima verossimilhança**, tem-se:

$$\hat{\sigma}_a^2 = \frac{1}{n} \sum_{t=1}^n a_t^2$$

onde

$a_t$  diferença entre os valores observados  $z_t$  e estimados  $\hat{z}_t$  ( $a_t = z_t - \hat{z}_t$ )



# Geração de séries sintéticas | modelos ARIMA: identificação

Critério de Akaike (AIC) [*Akaike, 1973*]\*

$$AIC(k) = n \ln \hat{\sigma}_a^2 + 2k$$

Critério de Akaike corrigido (AICc) [*Hurvich & Tsai, 1989*]\*\*

$$AICc(k) = AIC(k) + \frac{2(k)(k + 1)}{n - k - 1}$$

para  $n/k < 40$

---

\*Akaike, H. (1973). Information theory and an extension of the maximum likelihood principle. In B. N. Petrov & F. Csaki (Eds.), *Second International Symposium on Information Theory* (pp. 267–281). Budapest: Akademiai Kiado.

\*\* Hurvich, C. M., & Tsai, C.-L. (1989). Regression and time series model selection in small samples. *Biometrika*, 76(2), 297–307.

<https://doi.org/10.1093/biomet/76.2.297>

# Geração de séries sintéticas | modelos ARIMA: identificação

Critério Bayesiano (BIC) [Schwartz, 1978]\*

$$BIC(k) = n \ln \hat{\sigma}_a^2 + k \ln n$$

Quanto às penalidades:

AIC/AICc: fixa (baseada somente em  $k$ )

BIC: variável conforme o tamanho da amostra

A tendência é o BIC priorizar simplicidade sobre qualidade de ajuste e vice-versa



---

\*Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461–464. <https://doi.org/10.1214/aos/1176344136>



# Geração de séries sintéticas | modelos ARIMA: identificação

[Exemplo] Determinação dos critérios de informação para Salto Caxias e Itiquira II.

Salto Caxias



Itiquira II



Técnicas de decomposição de séries podem ajudar no entendimento aprofundado dos seus componentes

Os modelos de interesse para geração de séries sintéticas são da classe ARIMA (modelos estocásticos lineares de Box & Jenkins)  
representam muito bem a persistência das séries  
a construção do modelo passa pelas etapas: identificação, estimação, validação

Identificação: encontrar quais as componentes estarão presentes e as suas ordens



# ERHA7016 – Hidrologia Estocástica

Daniel Detzel  
detzel@ufpr.br