



ERHA7016 – Hidrologia Estocástica

# Geração de Séries Sintéticas (pt. 2)

estimação e validação

Daniel Detzel  
[detzel@ufpr.br](mailto:detzel@ufpr.br)

# Agenda

Geração de séries sintéticas

modelos ARIMA: estimação

modelos ARIMA: validação





# Geração de séries sintéticas | modelos ARIMA

Construção do modelo ARIMA (relembrando...)

## 1. Identificação do modelo

Determinar quais componentes farão parte da formulação

## 2. Estimação dos parâmetros

Obter os valores dos parâmetros envolvidos

## 3. Validação do modelo

Avaliar, teoricamente, se o ajuste é satisfatório

# GERAÇÃO DE SÉRIES SINTÉTICAS

modelos ARIMA: estimação

# Geração de séries sintéticas | modelos ARIMA: estimação

Objetivo: determinar os valores de  $\varphi_p$  ( $p = 1, 2, \dots$ ) e  $\theta_q$  ( $q = 1, 2, \dots$ )

Métodos a serem discutidos:

- Momentos

- Máxima Verossimilhança


Os parâmetros devem obedecer a certas restrições para que produzam modelos **estáveis**

- um modelo estável produz valores que flutuam no entorno de um nível médio sem “explodir”


# Geração de séries sintéticas | modelos ARIMA: estimação

## Representação da estabilidade e instabilidade do modelo AR(1)

Processo estável -  $\phi = 0,7$



Processo instável -  $\phi = 1,01$



# Geração de séries sintéticas | modelos ARIMA: estimação

As restrições aos parâmetros são denominadas condições de **estacionariedade** e **invertibilidade**

estacionariedade: aplicada à componente AR

invertibilidade: aplicada à componente MA

A compreensão dessas condições requer o entendimento da definição do **polinômio característico**

# Geração de séries sintéticas | modelos ARIMA: estimação

## Condição de estacionariedade:

Seja um modelo AR(p):

$$z_t = \varphi_1 z_{t-1} + \varphi_2 z_{t-2} + \cdots + \varphi_p z_{t-p} + a_t$$

Ele pode ser reescrito na forma:

$$z_t - \varphi_1 z_{t-1} - \varphi_2 z_{t-2} - \cdots - \varphi_p z_{t-p} = a_t$$



# Geração de séries sintéticas | modelos ARIMA: estimação

Usando o operador defasagem  $B$  (lembrando:  $B^k z_t = z_{t-k}$ ):

$$B^0 z_t - \varphi_1 B^1 z_t - \varphi_2 B^2 z_t - \cdots - \varphi_p B^p z_t = a_t$$

Colocando  $z_t$  em evidência:

$$\underbrace{(1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_p B^p)}_{\text{polinômio característico } \Phi(B)} z_t = a_t$$

polinômio característico  $\Phi(B)$

# Geração de séries sintéticas | modelos ARIMA: estimação

A condição de estacionariedade é verificada por meio deste polinômio característico  $\Phi(B)$

Para tanto, os coeficientes  $\varphi_i$  ( $i = 1, 2, \dots, p$ ) são inseridos no polinômio e as raízes  $B_i$  são determinadas

nota: as raízes podem ser complexas

Um modelo é estacionário quando a combinação de coeficientes  $\varphi_i$  ( $i = 1, 2, \dots, p$ ) produz raízes  $|B_i| > 1$

diz-se nesse caso que as raízes caem **fora do círculo unitário**

(círculo formado pelas porções reais e imaginária das raízes  $B_i$ )

# Geração de séries sintéticas | modelos ARIMA: estimação

Representação do círculo unitário e das raízes de  $\Phi(B)$  dos modelos AR(1) estável e instável mostrados anteriormente

obtenção do polinômio:

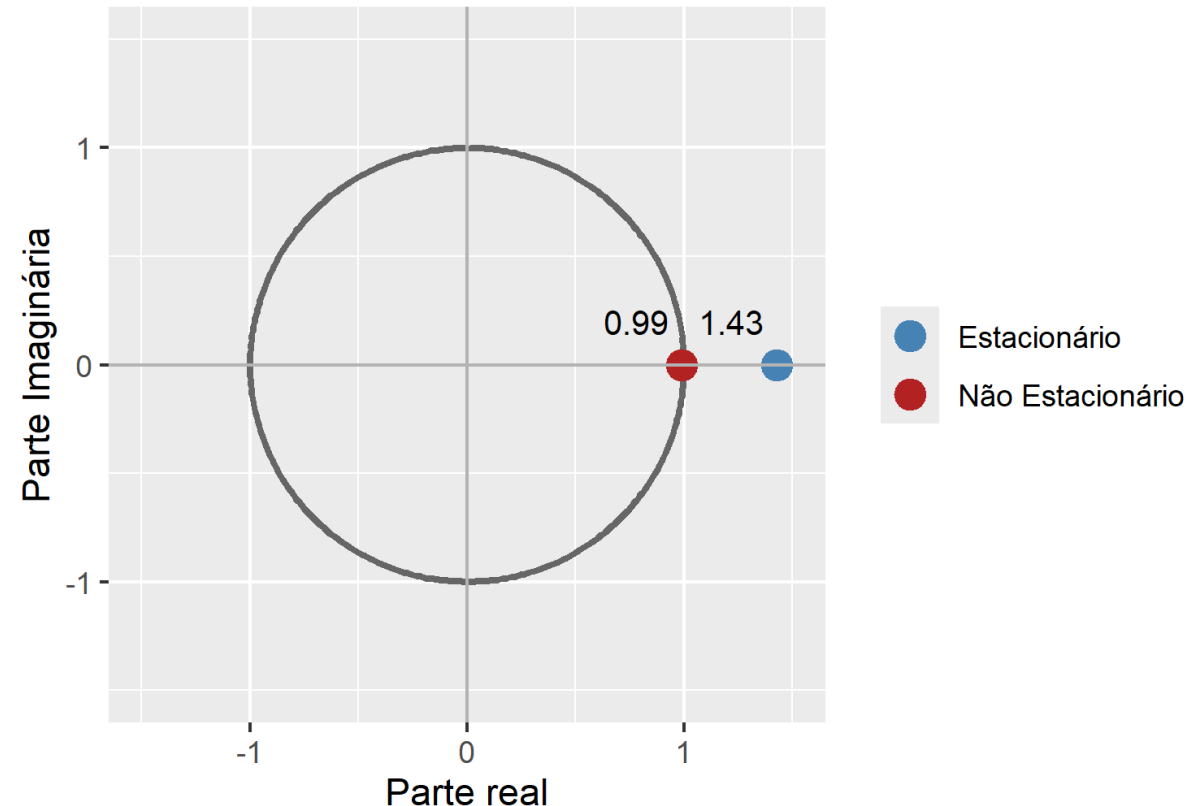
$$1 - \varphi_1 B = 0$$

AR(1) estacionário:

$$\varphi_1 = 0,7 \rightarrow B = 1,43$$

AR(1) não estacionário:

$$\varphi_1 = 1,01 \rightarrow B = 0,99$$



# Geração de séries sintéticas | modelos ARIMA: estimação

## Condição de invertibilidade:

Seja um modelo MA(q):

$$z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

Ele pode ser reescrito com operadores  $B$ :

$$z_t = \underbrace{(1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_p B^p)}_{\text{polinômio característico } \Theta(B)} a_t$$

# Geração de séries sintéticas | modelos ARIMA: estimação

A condição de invertibilidade é verificada por meio deste polinômio característico  $\Theta(B)$

Para tanto, os coeficientes  $\theta_i$  ( $i = 1, 2, \dots, q$ ) são inseridos no polinômio e as raízes  $B_i$  são determinadas

nota: as raízes podem ser complexas

Um modelo é invertível quando a combinação de coeficientes  $\theta_i$  produz raízes  $|B_i| > 1$

# Geração de séries sintéticas | modelos ARIMA: estimação

Em resumo:

Modelos puramente AR:

Estacionariedade atendida quando as raízes de  $\Phi(B)$  caem fora do círculo unitário

Modelos puramente MA:

Invertibilidade atendida quando as raízes de  $\theta(B)$  caem fora do círculo unitário

Modelos ARMA:

Ambas as condições devem ser atendidas



# Geração de séries sintéticas | modelos ARIMA: estimação

*[Exemplo]* No ajuste de um modelo Box & Jenkins, chegou-se à seguinte equação:

$$z_t = 0,6 \cdot z_{t-1} + 0,2 \cdot z_{t-2} + a_t + 0,1 \cdot a_{t-1} - 0,8 \cdot a_{t-2}$$

Pede-se:

- a) Identificar o modelo.
- b) Verificar se ele atende às condições de estacionariedade e invertibilidade.

# Geração de séries sintéticas | modelos ARIMA: estimação

## Método dos Momentos (MoM):

Recomendado para modelos **puramente AR**

produz estimadores enviesados quando da presença de componentes MA

Para modelos AR, considera-se a função de autocorrelação teórica:

$$\rho_k = \varphi_1 \rho_{k-1} + \varphi_2 \rho_{k-2} + \cdots + \varphi_p \rho_{k-p}, k > 0$$

onde

$\rho_k$  autocorrelação teórica com defasagem  $k$

$\varphi_i$  parâmetro AR de ordem  $i$  ( $i = 1, 2, \dots, p$ )

# Geração de séries sintéticas | modelos ARIMA: estimação

A expansão para múltiplas defasagens  $k$  ( $1, 2, \dots, p$ ) resulta nas equações de Yule-Walker:

$$\begin{aligned}\rho_1 &= \varphi_1 + \varphi_2 \rho_1 + \dots + \varphi_p \rho_{p-1} \\ \rho_2 &= \varphi_1 \rho_1 + \varphi_2 + \dots + \varphi_p \rho_{p-2} \\ &\vdots \\ \rho_p &= \varphi_1 \rho_{p-1} + \varphi_2 \rho_{p-2} + \dots + \varphi_p\end{aligned}$$

O MoM consiste em substituir os momentos teóricos (do modelo) pelos momentos empíricos (da série)

dado um modelo AR( $p$ ), substituem-se as correlações teóricas  $\rho_p$  por seus estimadores amostrais  $r_p$

# Geração de séries sintéticas | modelos ARIMA: estimação

Lembrando: os estimadores amostrais  $r_k$  são retirados da FAC (ou correlograma)

*[Exemplo]* Obter os estimadores para os modelos AR de primeira e segunda ordens.

1ª ordem: Modelo AR(1)  $\rightarrow p = 1$

Das equações de Yule-Walker:  $\rho_1 = \varphi_1$

Substituindo pelo estimador amostral:  $r_1 = \varphi_1$

$$\therefore \hat{\varphi}_1 = r_1$$

# Geração de séries sintéticas | modelos ARIMA: estimação

Este é um resultado particular muito importante!

interpretação: o coeficiente  $\hat{\varphi}_1$  de um modelo AR(1) é o próprio **coeficiente de correlação** (de Pearson) de primeira ordem  $r_1$

Desdobramento: todo modelo AR(1) será **sempre estacionário** (estável), pois:

$$1 - \varphi_1 B = 0$$

$$1 - r_1 B = 0$$

$$B = \frac{1}{r_1}$$

Como  $-1 < r_1 < 1$  por definição, tem-se que  $|B| > 1^*$

---

\* Em teoria,  $|r_1|$  pode assumir exatamente 1. Nesse caso,  $|B| = 1$  e o modelo é não estacionário. Porém, casos de correlação perfeita não acontecem no contexto de séries de fenômenos naturais.

# Geração de séries sintéticas | modelos ARIMA: estimação

2ª ordem: Modelo AR(2)  $\rightarrow p = 2$

Das equações de Yule-Walker:

$$\begin{cases} \rho_1 = \varphi_1 + \varphi_2 \rho_1 \\ \rho_2 = \varphi_1 \rho_1 + \varphi_2 \end{cases}$$

Substituindo pelos estimadores amostrais  $r_1$  e  $r_2$  e resolvendo o sistema, chega-se a:

$$\begin{aligned} \hat{\varphi}_1 &= \frac{r_1(1 - r_2)}{1 - r_1^2} \\ \hat{\varphi}_2 &= \frac{r_2 - r_1^2}{1 - r_1^2} \end{aligned}$$



# Geração de séries sintéticas | modelos ARIMA: estimação

## Método da Máxima Verossimilhança (MLE):

Recomendado para modelos **puramente MA** ou **mistos ARMA**

produz estimadores equivalentes às equações de Yule-Walker para modelos AR ajustados a séries com tamanho suficiente ( $n > 500$ ) e sob normalidade

Princípio: busca pelo melhor conjunto de parâmetros que associa os resultados do modelo às observações

As equações a seguir assumem que os dados são **normalmente distribuídos**

# Geração de séries sintéticas | modelos ARIMA: estimação

A função de verossimilhança para um processo ARMA é dada por:

$$L = \frac{1}{(2\pi\hat{\sigma}_a)^{n/2}} \cdot \exp \left[ -\frac{1}{2\hat{\sigma}_a} \cdot \sum_{t=1}^n \hat{a}_t (\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})^2 \right]$$

onde

$\hat{\boldsymbol{\varphi}}$  conjunto dos parâmetros AR estimados com base na amostra

$\hat{\boldsymbol{\theta}}$  conjunto dos parâmetros MA estimados com base na amostra

$\hat{a}_t$  série de resíduos obtidos do ajuste, com variância  $\hat{\sigma}_a$

O método busca o conjunto de parâmetros que maximiza a função  $L$

# Geração de séries sintéticas | modelos ARIMA: estimação

Matematicamente, é conveniente aplicar o logaritmo, chegando-se à função de log-verossimilhança:

$$\ln L = -n \cdot \ln \hat{\sigma}_a - \frac{S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})}{2\hat{\sigma}_a}$$

onde

$S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$  função soma dos quadrados dos resíduos:

$$S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}}) = \sum_{i=1}^n a_i^2$$

# Geração de séries sintéticas | modelos ARIMA: estimação

Qualquer conjunto de parâmetros que maximize a função  $S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$ , também maximiza a função  $\ln L$

O MLE é computacionalmente intenso pois a estimativa de  $S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$  requer cálculos recursivos para **toda série** e para **cada combinação** de parâmetros (recursividade: quando a estimativa do valor atual depende dos valores anteriores)

Lembra-se que as combinações devem respeitar as condições de estacionariedade e invertibilidade

# Geração de séries sintéticas | modelos ARIMA: estimação

*[Exemplo]* Obter a função  $S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$  para um modelo ARMA(1,1).

Modelo:

$$z_t = \varphi_1 z_{t-1} + a_t - \theta_1 a_{t-1}$$

Escreve-se a equação em função de  $a_t$ :

$$a_t = z_t - \varphi_1 z_{t-1} + \theta_1 a_{t-1}$$

Para os cálculos, a série  $z_t$  assume os valores observados

# Geração de séries sintéticas | modelos ARIMA: estimação

Variam-se os índices de tempo para  $t = p + q, \dots, n$

$$t = 2: a_2 = z_2 - \varphi_1 z_1 + \theta_1 a_1^*$$

$$t = 3: a_3 = z_3 - \varphi_1 z_2 + \theta_1 a_2 = z_3 - \varphi_1 z_2 + \theta_1 (z_2 - \varphi_1 z_1 + \theta_1 a_1)$$

$$\begin{aligned} t = 4: a_4 &= z_4 - \varphi_1 z_3 + \theta_1 a_3 \\ &= z_4 - \varphi_1 z_3 + \theta_1 [z_3 - \varphi_1 z_2 + \theta_1 (z_2 - \varphi_1 z_1 + \theta_1 a_1)] \end{aligned}$$

$\vdots$

$$t = n: a_n = z_n - \varphi_1 z_{n-1} + \theta_1 a_{n-1}$$

\* convencionou-se  $a_1 = E[a_t] = 0$

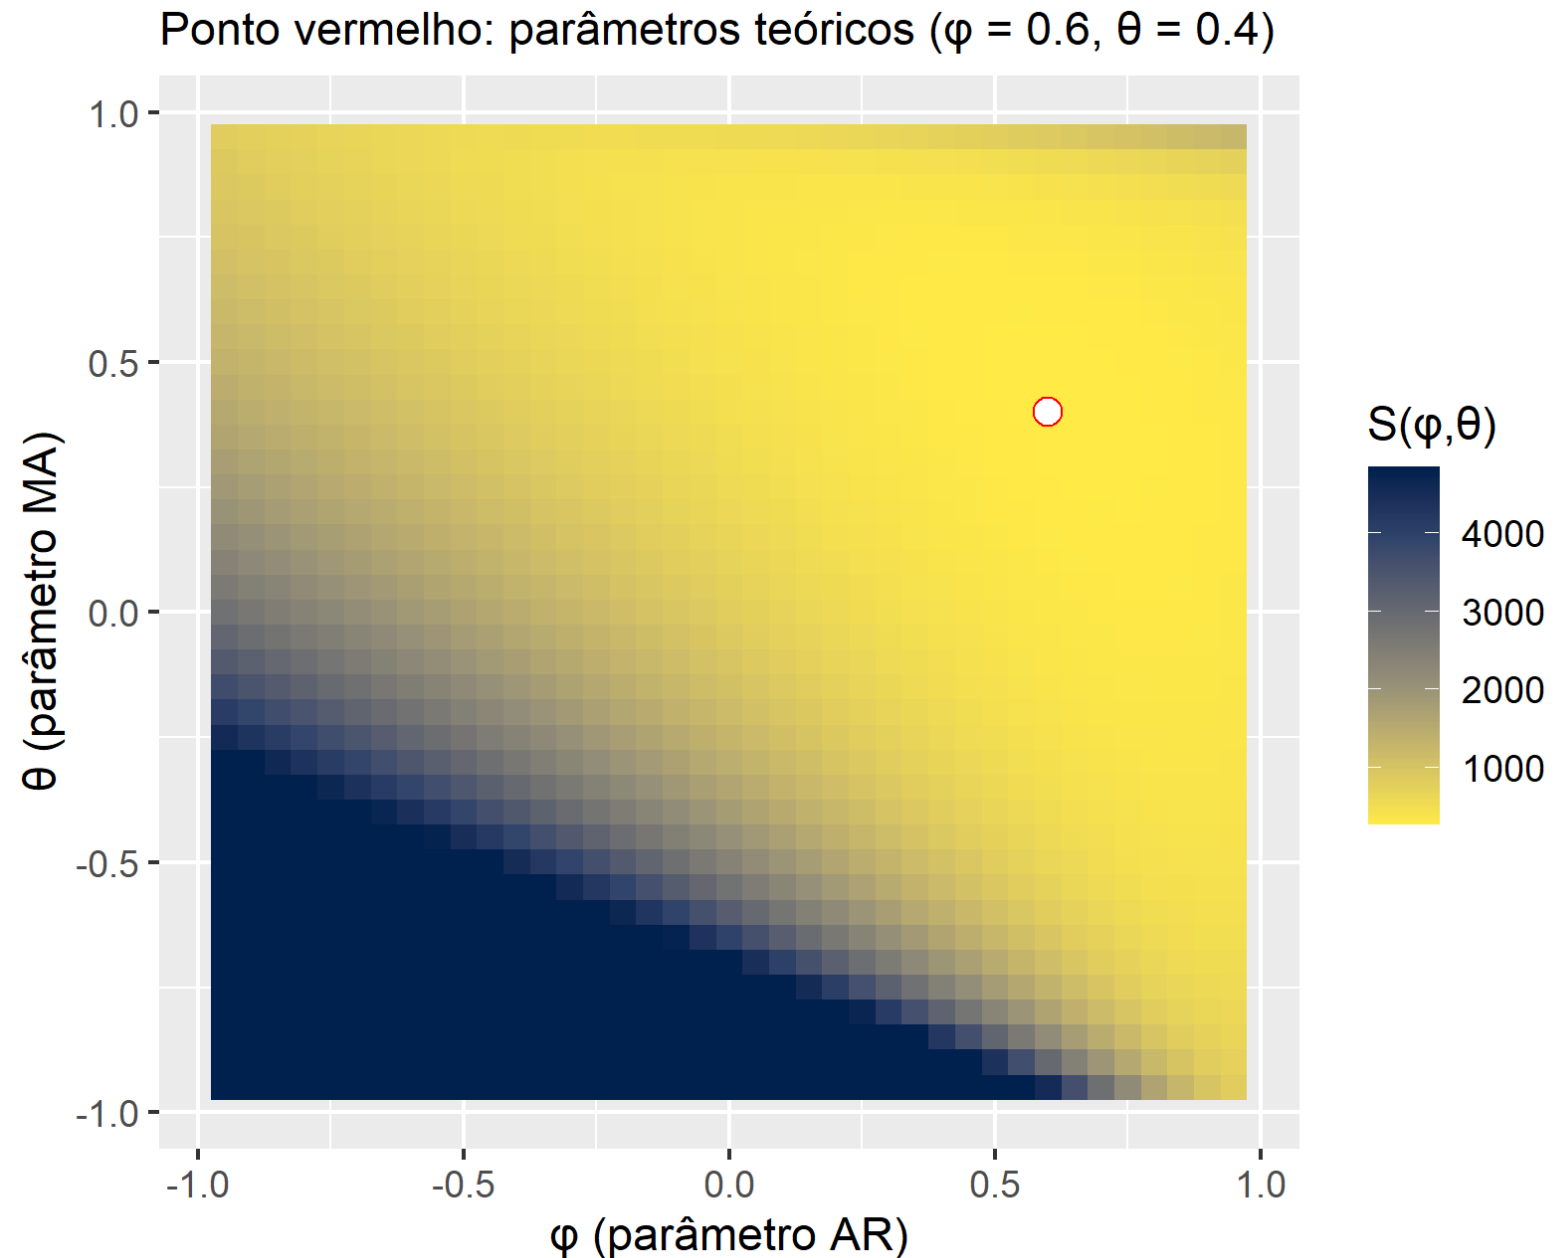


# Geração de séries sintéticas | modelos ARIMA: estimação

A cada novo valor para  $\hat{\varphi}$  ou  $\hat{\theta}$  a função  $S(\hat{\varphi}, \hat{\theta})$  é atualizada

---

Resultado da combinação de parâmetros para um modelo teórico conhecido



# GERAÇÃO DE SÉRIES SINTÉTICAS

modelos ARIMA: validação

# Geração de séries sintéticas | modelos ARIMA: validação

Última etapa antes do uso do modelo

Uma vez que os parâmetros foram estimados, a série de resíduos  $a_t$  resultantes do ajuste é calculada


caso a estimação tenha sido feita via MLE, a série  $a_t$  já estará calculada

Os resíduos do modelo funcionam como indicadores da qualidade do ajuste

um modelo bem ajustado produz resíduos com características estatísticas próximas a um ruído branco gaussiano



interpretação: as características da série  $z_t$  foram “filtradas” pelo, modelo, sobrando apenas os resíduos  $a_t$

# Geração de séries sintéticas | modelos ARIMA: validação



Comportamento esperado de  
um ruído branco gaussiano

(série utilizada para o próximo exemplo)



## Legenda

- Dist. Normal
- Resíduos

# Geração de séries sintéticas | modelos ARIMA: validação

## Independência:

### Procedimentos usuais

inspeção visual da FAC dos resíduos

testes estatísticos

Teste estatístico recomendado: Ljung-Box [*Box & Pierce, 1970*]

$H_0$ : Os resíduos não são correlacionados

$H_1$ : Os resíduos são correlacionados

# Geração de séries sintéticas | modelos ARIMA: validação

O procedimento se utiliza da própria função de autocorrelação para testar a significância até um *lag* pré-determinado  $k$

A estatística do teste é:

$$LB = n(n - 2) \sum_{k=1}^h \frac{r_k^2}{n - k}$$

onde

$n$  tamanho da série

$r_k^2$  autocorrelação de lag  $k$

$h$  máxima defasagem a ser testada



# Geração de séries sintéticas | modelos ARIMA: validação

A estatística  $LB$  tem distribuição qui-quadrado, com  $h - p - q$  graus de liberdade:

$$LB \sim \chi^2_{h-p-q}$$

Acerca do número de *lags* a ser considerado  
atribuído pelo analista de acordo com a série em análise  
[Box et al., 1994] recomendam  $h \cong 20$

## Homoscedasticidade:

Procedimento usual  
testes estatísticos

Teste estatístico recomendado: Breusch-Pagan [*Breusch & Pagan, 1978*]

$H_0$ : Homoscedasticidade presente (a variância dos resíduos é constante)

$H_1$ : Heteroscedasticidade presente (a variância dos resíduos não é constante)

# Geração de séries sintéticas | modelos ARIMA: validação

O teste se utiliza (novamente) da série de resíduos ao quadrado  $a_t^2$  como **indicador local** da variância

ou seja, a variância dos erros para cada observação  $z_t$   
para isso, ele assume que os resíduos são normalmente distribuídos

O procedimento envolve ajustar uma regressão linear à série  $a_t^2$ :

$$a_t^2 = \alpha t + \beta + \varepsilon_t$$

onde

$\alpha$  e  $\beta$  parâmetros da regressão

$\varepsilon_t$  resíduos da regressão (não confundir com o resíduo  $a_t$ !!)

# Geração de séries sintéticas | modelos ARIMA: validação

A estatística do teste é dada por:

$$BP = n \cdot R^2$$

onde

$n$  tamanho da série  $a_t^2$

$R^2$  coeficiente de determinação da regressão

A estatística  $BP$  tem distribuição qui-quadrado, com um grau de liberdade:

$$BP \sim \chi_1^2$$

# Geração de séries sintéticas | modelos ARIMA: validação

A lógica do teste é verificar se podemos explicar a variância dos resíduos com uma regressão em função do tempo

se o ajuste for bom (medido pelo  $R^2$ ), a resposta é afirmativa e os resíduos são heteroscedástico

# Geração de séries sintéticas | modelos ARIMA: validação

## Normalidade:

Procedimento usual

- análise visual via histogramas/densidades (ver aula 1)

- testes estatísticos (ver aula 2)

Nota: a condição de normalidade dos resíduos é a **mais difícil** de ser atingida. Portanto, admite-se certo relaxamento nessa condição

- pode-se verificar a **aproximação** dos resíduos da distribuição normal, via análises visuais

# Geração de séries sintéticas | modelos ARIMA: validação

*[Exemplo]* Verificar as condições de independência, homoscedasticidade e normalidade da série de resíduos do início do capítulo

## Independência (Ljung-Box)

```
Box.test(ruidoBranco, lag = 20, type = "Ljung-Box")  
X-squared = 14.134, df = 20, p-value = 0.8236
```

## Homoscedasticidade (Breusch-Pagan)

```
bptest(residuo ~ tempo)  
BP = 1.481, df = 1, p-value = 0.2236
```

## Normalidade (Shapiro-Wilk)

```
shapiro.test(ruidoBranco)  
W = 0.99906, p-value = 0.9001
```

# Resumo

Estimação: calcular os valores dos parâmetros do modelo identificado na etapa anterior

observar as condições de **estacionariedade** e **invertibilidade** para que o modelo seja estável

Base dos métodos de estimação

modelos puramente AR: Yule-Walker (MoM)

modelos puramente MA ou ARMA: soma dos quadrados dos resíduos (MLE)

Validação: verificação teórica do modelo, com base nos resíduos

comportamento de ruídos brancos gaussianos

independentes, homoscedásticos e (aprox.) normais





# ERHA7016 – Hidrologia Estocástica

Daniel Detzel  
detzel@ufpr.br