



ERHA7016 – Hidrologia Estocástica

Geração de Séries Sintéticas (pt. 2)

estimação e validação

Daniel Detzel
detzel@ufpr.br

Agenda

Geração de séries sintéticas

modelos ARIMA: estimação

modelos ARIMA: validação

Números pseudoaleatórios

Processo de geração de séries sintéticas



Geração de séries sintéticas | modelos ARIMA

Construção do modelo ARIMA (relembrando...)

1. Identificação do modelo

Determinar quais componentes farão parte da formulação

2. Estimação dos parâmetros

Obter os valores dos parâmetros envolvidos

3. Validação do modelo

Avaliar, teoricamente, se o ajuste é satisfatório

GERAÇÃO DE SÉRIES SINTÉTICAS

modelos ARIMA: estimação

Geração de séries sintéticas | modelos ARIMA: estimação

Objetivo: determinar os valores de φ_p ($p = 1, 2, \dots$) e θ_q ($q = 1, 2, \dots$)

Métodos a serem discutidos:

- Momentos

- Máxima Verossimilhança


Os parâmetros devem obedecer a certas restrições para que produzam modelos **estáveis**

- um modelo estável produz valores que flutuam no entorno de um nível médio sem “explodir”


Geração de séries sintéticas | modelos ARIMA: estimação

Representação da estabilidade e instabilidade do modelo AR(1)

Processo estável - $\phi = 0,7$



Processo instável - $\phi = 1,01$



Geração de séries sintéticas | modelos ARIMA: estimação

As restrições aos parâmetros são denominadas condições de **estacionariedade** e **invertibilidade**

estacionariedade: aplicada à componente AR

invertibilidade: aplicada à componente MA

A compreensão dessas condições requer o entendimento da definição do **polinômio característico**

Geração de séries sintéticas | modelos ARIMA: estimação

Condição de estacionariedade:

Seja um modelo AR(p):

$$z_t = \varphi_1 z_{t-1} + \varphi_2 z_{t-2} + \cdots + \varphi_p z_{t-p} + a_t$$

Ele pode ser reescrito na forma:

$$z_t - \varphi_1 z_{t-1} - \varphi_2 z_{t-2} - \cdots - \varphi_p z_{t-p} = a_t$$

Geração de séries sintéticas | modelos ARIMA: estimação

Usando o operador defasagem B (lembrando: $B^k z_t = z_{t-k}$):

$$B^0 z_t - \varphi_1 B^1 z_t - \varphi_2 B^2 z_t - \cdots - \varphi_p B^p z_t = a_t$$

Colocando z_t em evidência:

$$\underbrace{(1 - \varphi_1 B - \varphi_2 B^2 - \cdots - \varphi_p B^p)}_{\text{polinômio característico } \Phi(B)} z_t = a_t$$

polinômio característico $\Phi(B)$

Geração de séries sintéticas | modelos ARIMA: estimação

A condição de estacionariedade é verificada por meio deste polinômio característico $\Phi(B)$

Para tanto, os coeficientes φ_i ($i = 1, 2, \dots, p$) são inseridos no polinômio e as raízes B_i são determinadas

nota: as raízes podem ser complexas

Um modelo é estacionário quando a combinação de coeficientes φ_i ($i = 1, 2, \dots, p$) produz raízes $|B_i| > 1$

diz-se nesse caso que as raízes caem **fora do círculo unitário**

(círculo formado pelas porções reais e imaginária das raízes B_i)

Geração de séries sintéticas | modelos ARIMA: estimação

Representação do círculo unitário e das raízes de $\Phi(B)$ dos modelos AR(1) estável e instável mostrados anteriormente

obtenção do polinômio:


$$1 - \varphi_1 B = 0$$

AR(1) estacionário:

$$\varphi_1 = 0,7 \rightarrow B = 1,43$$

AR(1) não estacionário:

$$\varphi_1 = 1,01 \rightarrow B = 0,99$$



Geração de séries sintéticas | modelos ARIMA: estimação

Condição de invertibilidade:

Seja um modelo MA(q):

$$z_t = a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}$$

Ele pode ser reescrito com operadores B :

$$z_t = \underbrace{(1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_p B^p)}_{\text{polinômio característico } \Theta(B)} a_t$$

Geração de séries sintéticas | modelos ARIMA: estimação

A condição de invertibilidade é verificada por meio deste polinômio característico $\Theta(B)$

Para tanto, os coeficientes θ_i ($i = 1, 2, \dots, q$) são inseridos no polinômio e as raízes B_i são determinadas

nota: as raízes podem ser complexas

Um modelo é invertível quando a combinação de coeficientes θ_i produz raízes $|B_i| > 1$

Geração de séries sintéticas | modelos ARIMA: estimação

Em resumo:

Modelos puramente AR:

Estacionariedade atendida quando as raízes de $\Phi(B)$ caem fora do círculo unitário

Modelos puramente MA:

Invertibilidade atendida quando as raízes de $\theta(B)$ caem fora do círculo unitário

Modelos ARMA:

Ambas as condições devem ser atendidas

Geração de séries sintéticas | modelos ARIMA: estimação

[Exemplo] No ajuste de um modelo Box & Jenkins, chegou-se à seguinte equação:

$$z_t = 0,6 \cdot z_{t-1} + 0,2 \cdot z_{t-2} + a_t + 0,1 \cdot a_{t-1} - 0,8 \cdot a_{t-2}$$

Pede-se:

- a) Identificar o modelo.
- b) Verificar se ele atende às condições de estacionariedade e invertibilidade.

Geração de séries sintéticas | modelos ARIMA: estimação

[a] Relembrando a equação geral do modelo ARIMA:

$$(1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p)(1 - B)^d z_t = (1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q) a_t$$

O modelo do exemplo possui duas defasagens aplicadas a z_t e a a_t , além de não ter diferenciações. Portanto, trata-se de um ARMA(2,2), com parâmetros:

$$\varphi_1 = 0,6$$

$$\varphi_2 = 0,2$$

$$\theta_1 = -0,1 \text{ (observar o sinal na equação geral!!)}$$

$$\theta_2 = 0,8$$

Geração de séries sintéticas | modelos ARIMA: estimação

[b] Para avaliar as condições, é preciso obter as equações características. O modelo pode ser reescrito na forma:

$$z_t - 0,6 \cdot z_{t-1} - 0,2 \cdot z_{t-2} = a_t + 0,1 \cdot a_{t-1} - 0,8 \cdot a_{t-2}$$

Introduzindo o operador defasagem, chega-se a:

$$\underbrace{(1 - 0,6B - 0,2B^2)}_{\text{polinômio } \Phi(B)} z_t = \underbrace{(1 + 0,1B - 0,8B^2)}_{\text{polinômio } \Theta(B)} a_t$$

Geração de séries sintéticas | modelos ARIMA: estimação

Raízes do polinômio AR $(1 - 0,6B - 0,2B^2) = 0$:

$$B_1 = 1,19$$

$$B_2 = 4,19 \text{ (em módulo)}$$

Ambas são maiores do que 1 (portanto, fora do círculo unitário) → **estacionário!**

Raízes do polinômio MA $(1 + 0,1B - 0,8B^2) = 0$

$$B_1 = 1,18$$

$$B_2 = 1,06 \text{ (em módulo)}$$

Ambas são maiores do que 1 (portanto, fora do círculo unitário) → **invertível!**

Conclusão: o modelo atende a ambas as condições!

Geração de séries sintéticas | modelos ARIMA: estimação

Método dos Momentos (MoM):

Recomendado para modelos **puramente AR**

produz estimadores enviesados quando da presença de componentes MA

Para modelos AR, considera-se a função de autocorrelação teórica:

$$\rho_k = \varphi_1 \rho_{k-1} + \varphi_2 \rho_{k-2} + \cdots + \varphi_p \rho_{k-p}, k > 0$$

onde

ρ_k autocorrelação teórica com defasagem k

φ_i parâmetro AR de ordem i ($i = 1, 2, \dots, p$)

Geração de séries sintéticas | modelos ARIMA: estimação

A expansão para múltiplas defasagens k ($1, 2, \dots, p$) resulta nas equações de Yule-Walker:

$$\begin{aligned}\rho_1 &= \varphi_1 + \varphi_2 \rho_1 + \dots + \varphi_p \rho_{p-1} \\ \rho_2 &= \varphi_1 \rho_1 + \varphi_2 + \dots + \varphi_p \rho_{p-2} \\ &\vdots \\ \rho_p &= \varphi_1 \rho_{p-1} + \varphi_2 \rho_{p-2} + \dots + \varphi_p\end{aligned}$$

O MoM consiste em substituir os momentos teóricos (do modelo) pelos momentos empíricos (da série)

dado um modelo AR(p), substituem-se as correlações teóricas ρ_p por seus estimadores amostrais r_p

Geração de séries sintéticas | modelos ARIMA: estimação

Lembrando: os estimadores amostrais r_k são retirados da FAC (ou correlograma)

[Exemplo] Obter os estimadores para os modelos AR de primeira e segunda ordens.

1ª ordem: Modelo AR(1) $\rightarrow p = 1$

Das equações de Yule-Walker: $\rho_1 = \varphi_1$

Substituindo pelo estimador amostral: $r_1 = \varphi_1$

$$\therefore \hat{\varphi}_1 = r_1$$

Geração de séries sintéticas | modelos ARIMA: estimação

Este é um resultado particular muito importante!

interpretação: o coeficiente $\hat{\varphi}_1$ de um modelo AR(1) é o próprio **coeficiente de correlação** (de Pearson) de primeira ordem r_1

Desdobramento: todo modelo AR(1) será **sempre estacionário** (estável), pois:

$$1 - \varphi_1 B = 0$$

$$1 - r_1 B = 0$$

$$B = \frac{1}{r_1}$$

Como $-1 < r_1 < 1$ por definição, tem-se que $|B| > 1^*$

* Em teoria, $|r_1|$ pode assumir exatamente 1. Nesse caso, $|B| = 1$ e o modelo é não estacionário. Porém, casos de correlação perfeita não acontecem no contexto de séries de fenômenos naturais.

Geração de séries sintéticas | modelos ARIMA: estimação

2ª ordem: Modelo AR(2) $\rightarrow p = 2$

Das equações de Yule-Walker:

$$\begin{cases} \rho_1 = \varphi_1 + \varphi_2 \rho_1 \\ \rho_2 = \varphi_1 \rho_1 + \varphi_2 \end{cases}$$

Substituindo pelos estimadores amostrais r_1 e r_2 e resolvendo o sistema, chega-se a:

$$\begin{aligned} \hat{\varphi}_1 &= \frac{r_1(1 - r_2)}{1 - r_1^2} \\ \hat{\varphi}_2 &= \frac{r_2 - r_1^2}{1 - r_1^2} \end{aligned}$$

Geração de séries sintéticas | modelos ARIMA: estimação

Método da Máxima Verossimilhança (MLE):

Recomendado para modelos **puramente MA** ou **mistos ARMA**

produz estimadores equivalentes às equações de Yule-Walker para modelos AR ajustados a séries com tamanho suficiente ($n > 500$) e sob normalidade

Princípio: busca pelo melhor conjunto de parâmetros que associa os resultados do modelo às observações

As equações a seguir assumem que os dados são **normalmente distribuídos**

Geração de séries sintéticas | modelos ARIMA: estimação

A função de verossimilhança para um processo ARMA é dada por:

$$L = \frac{1}{(2\pi\hat{\sigma}_a)^{n/2}} \cdot \exp \left[-\frac{1}{2\hat{\sigma}_a} \cdot \sum_{t=1}^n \hat{a}_t (\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})^2 \right]$$

onde

$\hat{\boldsymbol{\varphi}}$ conjunto dos parâmetros AR estimados com base na amostra

$\hat{\boldsymbol{\theta}}$ conjunto dos parâmetros MA estimados com base na amostra

$\hat{a}_t$ série de resíduos obtidos do ajuste, com variância $\hat{\sigma}_a$

O método busca o conjunto de parâmetros que maximiza a função L

Geração de séries sintéticas | modelos ARIMA: estimação

Matematicamente, é conveniente aplicar o logaritmo, chegando-se à função de log-verossimilhança:

$$\ln L = -n \cdot \ln \hat{\sigma}_a - \frac{S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})}{2\hat{\sigma}_a}$$

onde

$S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$ função soma dos quadrados dos resíduos:

$$S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}}) = \sum_{i=1}^n a_i^2$$

Geração de séries sintéticas | modelos ARIMA: estimação

Qualquer conjunto de parâmetros que maximize a função $S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$, também maximiza a função $\ln L$

O MLE é computacionalmente intenso pois a estimativa de $S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$ requer cálculos recursivos para **toda série** e para **cada combinação** de parâmetros (recursividade: quando a estimativa do valor atual depende dos valores anteriores)

Lembra-se que as combinações devem respeitar as condições de estacionariedade e invertibilidade

Geração de séries sintéticas | modelos ARIMA: estimação

[Exemplo] Obter a função $S(\hat{\boldsymbol{\varphi}}, \hat{\boldsymbol{\theta}})$ para um modelo ARMA(1,1).

Modelo:

$$z_t = \varphi_1 z_{t-1} + a_t - \theta_1 a_{t-1}$$

Escreve-se a equação em função de a_t :

$$a_t = z_t - \varphi_1 z_{t-1} + \theta_1 a_{t-1}$$

Para os cálculos, a série z_t assume os valores observados

Geração de séries sintéticas | modelos ARIMA: estimação

Variam-se os índices de tempo para $t = p + q, \dots, n$

$$t = 2: a_2 = z_2 - \varphi_1 z_1 + \theta_1 a_1^*$$

$$t = 3: a_3 = z_3 - \varphi_1 z_2 + \theta_1 a_2 = z_3 - \varphi_1 z_2 + \theta_1 (z_2 - \varphi_1 z_1 + \theta_1 a_1)$$

$$\begin{aligned} t = 4: a_4 &= z_4 - \varphi_1 z_3 + \theta_1 a_3 \\ &= z_4 - \varphi_1 z_3 + \theta_1 [z_3 - \varphi_1 z_2 + \theta_1 (z_2 - \varphi_1 z_1 + \theta_1 a_1)] \end{aligned}$$

$\vdots$


$$t = n: a_n = z_n - \varphi_1 z_{n-1} + \theta_1 a_{n-1}$$

* convencionou-se $a_1 = E[a_t] = 0$

Geração de séries sintéticas | modelos ARIMA: estimação

A cada novo valor para $\hat{\varphi}$ ou $\hat{\theta}$ a função $S(\hat{\varphi}, \hat{\theta})$ é atualizada

Resultado da combinação de parâmetros para um modelo teórico conhecido



GERAÇÃO DE SÉRIES SINTÉTICAS

modelos ARIMA: validação

Geração de séries sintéticas | modelos ARIMA: validação

Última etapa antes do uso do modelo

Uma vez que os parâmetros foram estimados, a série de resíduos a_t resultantes do ajuste é calculada


caso a estimação tenha sido feita via MLE, a série a_t já estará calculada

Os resíduos do modelo funcionam como indicadores da qualidade do ajuste

um modelo bem ajustado produz resíduos com características estatísticas próximas a um ruído branco gaussiano



interpretação: as características da série z_t foram “filtradas” pelo, modelo, sobrando apenas os resíduos a_t

Geração de séries sintéticas | modelos ARIMA: validação




Comportamento esperado de
um ruído branco gaussiano

(série utilizada para o próximo exemplo)



Legenda



Geração de séries sintéticas | modelos ARIMA: validação

Independência:

Procedimentos usuais

inspeção visual da FAC dos resíduos

testes estatísticos

Teste estatístico recomendado: Ljung-Box [*Box & Pierce, 1970*]

H_0 : Os resíduos não são correlacionados

H_1 : Os resíduos são correlacionados

Geração de séries sintéticas | modelos ARIMA: validação

O procedimento se utiliza da própria função de autocorrelação para testar a significância até um *lag* pré-determinado k

A estatística do teste é:

$$LB = n(n - 2) \sum_{k=1}^h \frac{r_k^2}{n - k}$$

onde

n tamanho da série

r_k^2 autocorrelação de lag k

h máxima defasagem a ser testada

Geração de séries sintéticas | modelos ARIMA: validação

A estatística LB tem distribuição qui-quadrado, com $h - p - q$ graus de liberdade:

$$LB \sim \chi^2_{h-p-q}$$

Acerca do número de *lags* a ser considerado
atribuído pelo analista de acordo com a série em análise
[Box et al., 1994] recomendam $h \cong 20$

Homoscedasticidade:

Procedimento usual
testes estatísticos

Teste estatístico recomendado: Breusch-Pagan [*Breusch & Pagan, 1978*]

H_0 : Homoscedasticidade presente (a variância dos resíduos é constante)

H_1 : Heteroscedasticidade presente (a variância dos resíduos não é constante)

Geração de séries sintéticas | modelos ARIMA: validação

O teste se utiliza (novamente) da série de resíduos ao quadrado a_t^2 como **indicador local** da variância

ou seja, a variância dos erros para cada observação z_t
para isso, ele assume que os resíduos são normalmente distribuídos

O procedimento envolve ajustar uma regressão linear à série a_t^2 :

$$a_t^2 = \alpha t + \beta + \varepsilon_t$$

onde

α e β parâmetros da regressão

ε_t resíduos da regressão (não confundir com o resíduo a_t !!)

Geração de séries sintéticas | modelos ARIMA: validação

A estatística do teste é dada por:

$$BP = n \cdot R^2$$

onde

n tamanho da série a_t^2

R^2 coeficiente de determinação da regressão

A estatística BP tem distribuição qui-quadrado, com um grau de liberdade:

$$BP \sim \chi_1^2$$

Geração de séries sintéticas | modelos ARIMA: validação

A lógica do teste é verificar se podemos explicar a variância dos resíduos com uma regressão em função do tempo

se o ajuste for bom (medido pelo R^2), a resposta é afirmativa e os resíduos são heteroscedástico

Geração de séries sintéticas | modelos ARIMA: validação

Normalidade:

Procedimento usual

- análise visual via histogramas/densidades (ver aula 1)

- testes estatísticos (ver aula 2)

Nota: a condição de normalidade dos resíduos é a **mais difícil** de ser atingida. Portanto, admite-se certo relaxamento nessa condição

- pode-se verificar a **aproximação** dos resíduos da distribuição normal, via análises visuais

Geração de séries sintéticas | modelos ARIMA: validação

[Exemplo] Verificar as condições de independência, homoscedasticidade e normalidade da série de resíduos do início do capítulo

Independência (Ljung-Box)

```
Box.test(ruidoBranco, lag = 20, type = "Ljung-Box")  
X-squared = 14.134, df = 20, p-value = 0.8236
```

Homoscedasticidade (Breusch-Pagan)

```
bptest(residuo ~ tempo)  
BP = 1.481, df = 1, p-value = 0.2236
```

Normalidade (Shapiro-Wilk)

```
shapiro.test(ruidoBranco)  
W = 0.99906, p-value = 0.9001
```

NÚMEROS PSEUDOALEATÓRIOS

Números pseudoaleatórios

Números pseudoaleatórios são a base do **Método de Monte Carlo**
possibilitam a construção dos diversos cenários para as simulações

Acerca do termo “pseudo”

não é possível obter uma garantia de **aleatoriedade absoluta** em um processo de geração de variáveis

a existência de um método para a geração faz com que as variáveis se tornem **previsíveis**

o termo “números aleatórios” é considerado equivocado → números **pseudoaleatórios**

Números pseudoaleatórios

Todos os geradores possuem um ponto de partida, denominado **semente*** valor inicial a partir do qual os algoritmos começam a calcular a sequência de números

uma mesma semente resulta em uma mesma sequência de números

pode-se trabalhar com sementes dinâmicas, utilizando-se por exemplo:

$$x_0 = \text{ano} - 2000 + 10\{(\text{mês} - 1) + 12\{(\text{dia} - 1) + 31[\text{hora} + 24(\text{min} + 60\text{seg})]\}\}$$

onde

$$0 \leq x_0 \leq 3.214.079.999$$

* Nos códigos das aulas está sendo utilizada uma semente fixa para garantir a reprodutibilidade dos resultados (função `seed ( )`)

Números pseudoaleatórios

Os conjuntos de números pseudoaleatórios possuem **distribuições de probabilidade específica**

parte-se da geração de números uniformemente distribuídos
adapta-se para números com as distribuições desejadas (métodos disponíveis em *[Kaviski, 2006, Apêndice A]*)

De interesse para modelos ARIMA: números pseudoaleatórios normalmente distribuídos com média zero e variância σ_a^2 :

$$a_t \sim N(0, \sigma_a^2)$$

PROCESSO DE GERAÇÃO DE SÉRIES SINTÉTICAS

Geração de séries sintéticas

Depois de terminado o processo identificação-estimação-validação, o modelo está pronto para gerar as séries sintéticas

A equação para geração é a mesma equação do modelo, porém rearranjada de modo a isolar a variável z_t

a partir deste momento, z_t não mais representa a série histórica
convenciona-se alterar a denominação para z'_t , representando as **séries sintéticas**

[Exemplo]

$$\text{AR}(1): z'_t = \hat{\varphi}_1 z'_{t-1} + a_t$$

$$\text{ARMA}(1,1): z'_t = \hat{\varphi}_1 z'_{t-1} + a_t - \hat{\theta}_1 a_{t-1}$$

Geração de séries sintéticas

Fazendo $t = 1, 2, \dots, n'$, onde n' é o tamanho **desejado**, constrói-se a série sintética

n' não precisa, necessariamente, ser idêntico ao da série histórica

Valores iniciais para z_{t-1} e a_{t-1} podem ser zero ou os últimos valores observados na série histórica


(aqui está a diferença entre gerar séries e prever séries!)

A cada novo avanço de t , a_t é substituída por números pseudoaleatórios distribuídos $a_t \sim N(0, \hat{\sigma}_a^2)$. Para tanto:

1. Gera-se uma variável $a'_t \sim N(0, 1)$ usando métodos convencionais
2. Aplica-se a transformação $a_t = \hat{\mu}_a + a'_t \hat{\sigma}_a = a'_t \hat{\sigma}_a$

Geração de séries sintéticas

Para eliminar a influência dos valores iniciais, gera-se uma série maior do que a desejada e ignoram-se os primeiros valores



Resumo

Estimação: calcular os valores dos parâmetros do modelo identificado na etapa anterior

observar as condições de [estacionariedade](#) e [invertibilidade](#)

Base dos métodos de estimação

modelos puramente AR: Yule-Walker (MoM)

modelos puramente MA ou ARMA: soma dos quadrados dos resíduos (MLE)

Validação: verificação teórica do modelo, com base nos resíduos

espera-se que sejam: independentes, homoscedásticos e (aprox.) normais

Números pseudoaleatórios são ferramentas para a geração de séries sintéticas



ERHA7016 – Hidrologia Estocástica

Daniel Detzel
detzel@ufpr.br